17-基于数据挖掘的电力负荷预测 最终报告

成员: 蔡静轩(3220180783), 王峤(3220180867)

此报告记录我们所采用的模型、方法以及最终评估结果。

我们取最终得到的DataSet7.0.csv为实验数据集,随机划分 2016-2017 年的数据,取 30%的数据集为测试数据集,通过暴力寻参(6 折交叉验证)测试多种模型的效果。评价指标为R²与测试集上总的MAPE。

一、线性模型

线性模型主要包括了线性回归、Lasso回归、岭回归和ElasticNet回归。结果显示在以半小时为刻度区分电机的数据集上,4种回归的效果几乎一样。R²接近 0.86,MAPE更是只有 0.5%。而在以天为刻度合并负荷的数据集上,效果更是几乎能够百分之百的预测准确。模型的最佳参数、最佳系数如下图所示。结果显示Hour、Equsid、F_half、F_day、F_week、rh_10 为主要特征。我们也依照电机序号将数据集划分为 6 堆,单独做模型测试,结果几乎一致。

以半小时为刻度区分电机的模型结果如下图所示:

```
!!! Welcome to Linear Model discovery hall !!!

The features used are:
['Month' 'Day' 'Hour' 'Half' 'Equsid' 'F_half' 'F_day' 'F_week'
    'dayOfWeek' 'isHoliday' 'isWorkday' 'Season' 't_10' 'rh_10']

########## The result of Linear regression #########

Best parameters set found: {'normalize': True}

Best score found: 0.8566A84967073135

Optimized Score R2: 0.8526998856862216

Optimized Score MAPE: 0.005292581550465456

Best linear model parameter: [ 1.81353545e-01 1.30958519e-01 -7.28537105e-01 -2.96691183e-01
    9.46484990e-01 1.00061161e+02 2.95445379e+00 3.22909836e+00
    -2.05883279e-02 -1.84352304e-01 3.53569026e-01 3.89634248e-01
    -2.61736312e-02 -1.47179174e+00]

########## The result of ElasticNet regression ########

Best parameters set found: {'alpha': 0.01, 'l1_ratio': 0.9, 'normalize': False}

Best parameters set found: {'alpha': 0.01, 'l1_ratio': 0.9, 'normalize': False}

Optimized Score R2: 0.8527074625150409

Optimized Score MAPE: 0.00528352541012588

Best linear model parameter: [ 1.69702606e-01 1.22918355e-01 -7.13771256e-01 -2.87358190e-01
    9.50320775e-01 9.99270236e+01 2.98711792e+00 3.25491709e+00
    -2.79705840e-02 -1.81102717e-01 3.42914041e-01 3.84473721e-01
    -2.17029623e-02 -1.46667582e+00]

Actual number of iterations: 8
```

下图为以天为刻度合并负荷的模型结果:

二、KNN

KNN的结果确实不理想,原因是KNN本身无法很好的利用分类特征。

```
######### The result of KNN regression #########

Best parameters set found: {'n_neighbors': 10, 'p': 2, 'weights': 'distance'}

Best score found: 0.788470257753118

Optimized Score R2: 0.8226290135393847

Optimized Score MAPE: 0.09251028818179605
```

三、集成学习

可以看出集成学习的效果也相当不错。

```
####### The result of Adaboost regression ########
Best parameters set found: {'learning_rate': 1, 'loss': 'linear', 'n_estimators': 260}
Optimized Score R2: 0.6895773707904562
Optimized Score MAPE: 0.07036464509688001
Best adaboost model parameter : [2.36226894e-02 4.07345777e-02 7.21488859e-02 7.11987503e-02
8.03164388e-03 1.07857310e-02 9.28068706e-02 7.00137529e-02
 7.58993651e-02 8.59939099e-02 2.68216290e-01 1.58807698e-04
####### The result of Random Forest regression ########
Best parameters set found: {'n_estimators': 230}
Optimized Score R2: 0.6634557651485685
Optimized Score MAPE: 0.009244939143775438
Best RF model parameter: [2.49684718e-02 3.29730181e-02 7.35473357e-02 5.33438251e-02
3.95886698e-02 6.05303491e-02 2.72459327e-02 1.35701735e-02
8.66795957e-031
####### The result of GBDT regression ########
Best parameters set found: {'learning_rate': 0.1, 'loss': 'huber', 'n_estimators': 55}
Best score found: 0.526180750023044
Optimized Score R2: 0.6515486248738318
Optimized Score MAPE: 0.07730897160701472
Best GBDT model parameter : [0.00500614 0.00699185 0.03470632 0.0120593 0.03031395 0.02031912
 0.02532315 0.03195597 0.04415288 0.00327689 0.04075306 0.0408889
 0.06442619 0.10403641 0.53046796 0.00068415 0.00463777]
```

四、基于树的模型

从理论上分析,线性模型和KNN都很难利用到分类特征的信息,而基于树的模型则恰恰相反,因此使用Adaboost、Random Forest、GBDT的最佳参数重新训练 2016~2017 年的数据,并在 2018 年的数据集上做验证。

结果如下所示:

Ensemble model features selection: [0.02387685 0.03471238 0.06404552 0.04820721 0.04343014 0.05311927

0.02895269 0.01255174 0.02458419 0.08422578 0.0662677 0.08458858

Adaboost模型的R²达到了 0.74,总MAPE为 0.66%,而日MAPE绝对值的均值为 32%,这表明模型对整体的拟合较好,但是存在一些局部的过拟合或欠拟合。

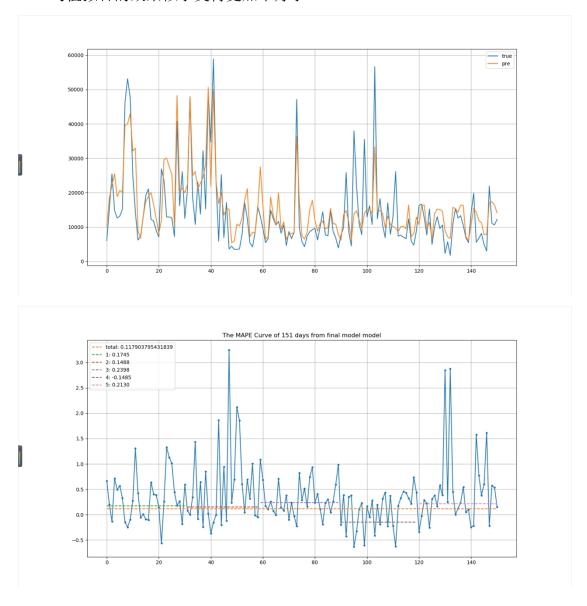
同样的RF与GBDT模型得出的结果与Adaboost类似。

模型融合

考虑用线性回归或均值拟合 2018 年的负荷曲线。

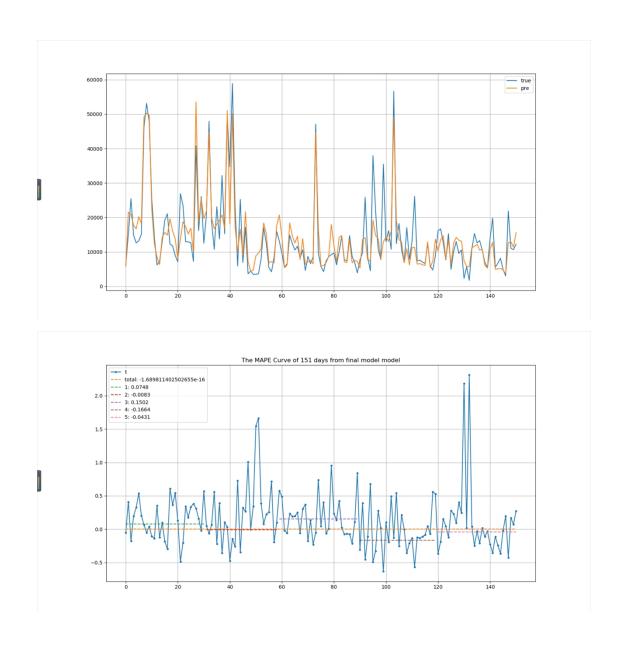
1、 均值拟合

均值拟合的效果似乎变得更加不好了。



2、 线性回归

使用线性回归拟合负荷曲线的效果较好,5个月总的MAPE几乎为0。3/4月份的MAPE也得到了一定的修正。



总结

在此项目过程中,结合课上所学内容,对数据做了大量的清洗和预处理工作,保证了后面实验过程的顺利进行。通过线性模型、KNN、集成学习及基于树的模型,得到了较好的效果,完成了预设目标。同时,对于相对应的算法、模型及工具等有了进一步的认识,得到了实际的经验。